

DATA SCIENCE EN EL PRICING Y LA TARIFICACIÓN

- A. Agenda / La idea de este curso
- B. Introducción:
 - a) ¿Qué es un Seguro?
 - b) Modelo de negocio
- C. GLM en Seguros
- D. Modelos tradicionales (avanzados)



Agenda

Topic	Formato	Fecha
Introducción: Historia breve de analytics en Seguros Modelos tradicionales (avanzados)	PPT Discusión abierta	25/03/2019
Aplicación para el pricing Ejemplo práctico de como llegar a una prima GLM – Poisson, Binomial, Gamma, Tweedy	PPT R-Studio ADDACTIS Pricing	01/04/2019
Modelos en el sector de Seguros Ejemplos prácticos del mundo de seguros Procesos, Scoring, Cluster, Optimización, Zonificación (geo-spatial smooting). “La nueva generación” de Modelos ¿A dónde van los modelos en el seguro?	PPT Discusión abierta	08/04/2019

Idea / Enfoque

Topic

La vida real en una compañía de seguros

Muchas preguntas / Es para vosotros

Oportunidades y desafíos actuales



Presentación

Michael Noack

Director
Actuarial & Advanced Analytics
Deloitte/ España

Formación académica:



Licenciado en Matemáticas por la Universidad Estatal de Moscú
Actuario DAV (Alemania)

Experiencia:



Direct.
Seguros



Profesor Asociado:



Conocimientos:



HYPERION



B. Introducción:

**¿Qué es un Seguro?
Modelo de negocio**

Tipos de seguros:

Seguros de vida

- ✓ N siniestros
- ✓ Duración
- ✓ Costes



Análisis – matemática financiera
Tablas de mortalidad

Seguros de no vida

- ✓ N siniestros
- ✓ Duración
- ✓ Costes



Análisis – métodos estadísticos avanzados



Hogar



Autos



Vida



Salud



Ahorro

Tipos de seguros:

Seguros de vida



Swiss Re AG



Swiss Re: "El cambio de tendencia en la mortalidad puede hacer muy caros los seguros de Vida"

José Antonio Herce (AFI): "El riesgo de longevidad hoy ya no es asegurable"
- 25 noviembre, 2016
El presidente de la Mutualidad, Enrique Sanz Fernández-Lomana, y Rafael Navas Lanchas, director general de la entidad, presentaron la jornada, que incluyó un doble...

Seguros de no vida



Unespa: "La digitalización traerá muchos beneficios al sector, pero sería un error instalarse en el optimismo"

Insurance Revolution 2018: Predicción y personalización, claves de la transformación digital



Hogar



Autos



Vida



Salud



Ahorro

La idea de seguros:

Cambiar un riesgo con un coste desconocido (Siniestro) por un precio fijo (Prima)

- No le gusta el riesgo
- Legal – seguros obligatorios
- Costes impagables

Objetivo: Poner los precios en función del riesgo

- Con la de-regulación – competencia por los mejores clientes
- Afinar métodos de estimación del riesgo cada vez más

Si nos equivocamos → anti selección

Los “buenos” salen
Los “malos” entran

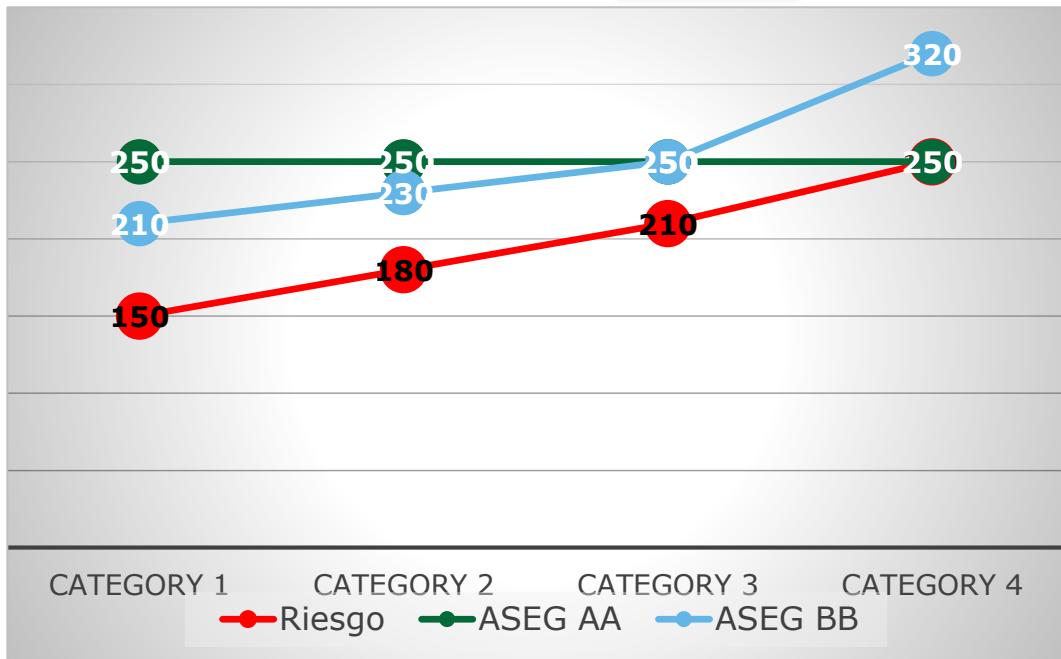
SEGUROS = MUCHOS DATOS

- No hay problemas de BIAS (n o $n-1$ etc)
- Todo es significativo desde el punto de vista estadístico
- Hay que diferenciar entre significativo estadístico y significativo económico (€€)

Anti selección:

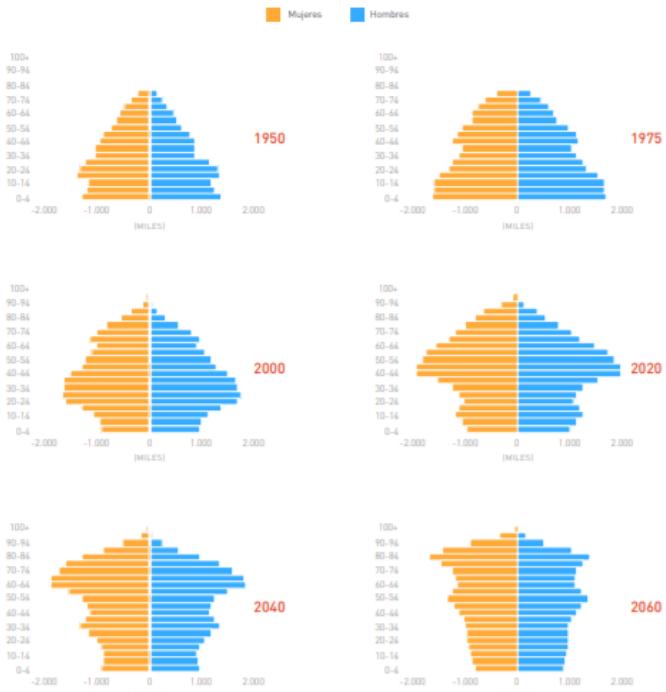
Si nos equivocamos → anti selección

Los “buenos” salen
Los “malos” entran



	N Clientes	N Clientes ASEG AA	N Clientes ASEG BB	Margin ASEG AA	Margin ASEG BB
CAT1	1000	300	700	30.000	42.000
CAT2	1000	400	600	28.000	30.000
CAT3	1000	500	500	20.000	20.000
CAT4	1000	800	200	0	14.000
TOTAL	4000	2000	2000	78.000	106.000

Gráfica 1.2-a
España: evolución de la pirámide poblacional, 1950-2100

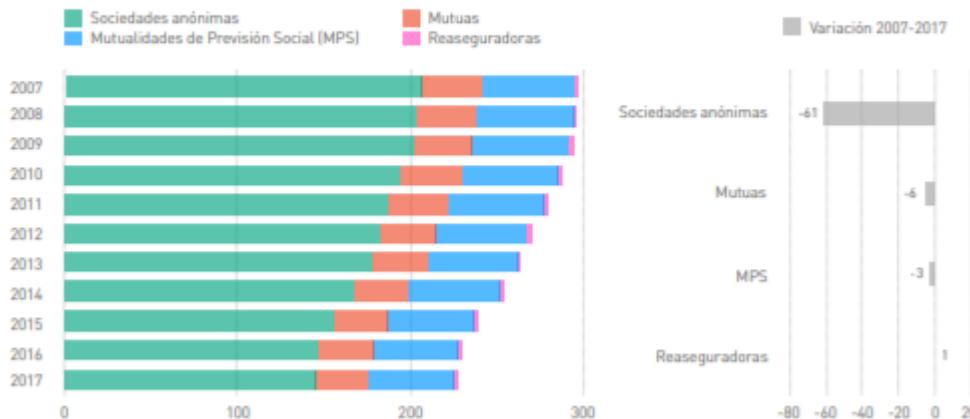


Fundación **MAPFRE**

EL MERCADO ESPAÑOL DE SEGUROS EN 2017

Servicio de Estudios de MAPFRE

Gráfica 2.3
España: número de entidades operativas por tipo de régimen, 2007-2017
(número de entidades)

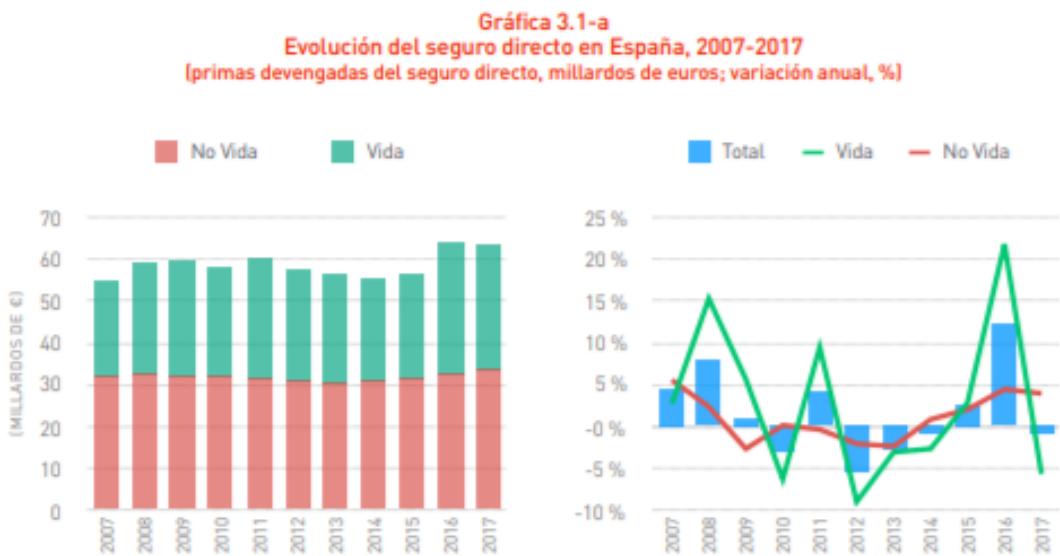


Fuente: Servicio de Estudios de MAPFRE (con datos de la DGSFP)

Prima Total: 63.410 millones de euros

Un 5,4% del PIB aprox.

Crecimiento: desde el 2015 vuelve a crecer.



Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

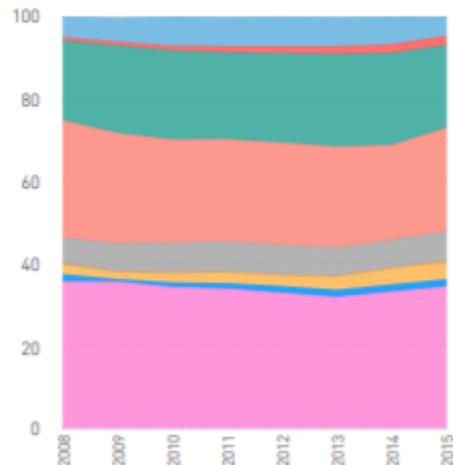
https://www.fundacionmapfre.org/documentacion/publico/i18n/catalogo_imagenes/grupo.cmd?path=1097438

EL MERCADO ESPAÑOL DE SEGUROS EN 2017

Servicio de Estudios de MAPFRE

Gráfica 2.4-b
España: distribución porcentual de la cartera del negocio de No Vida por canales (%)

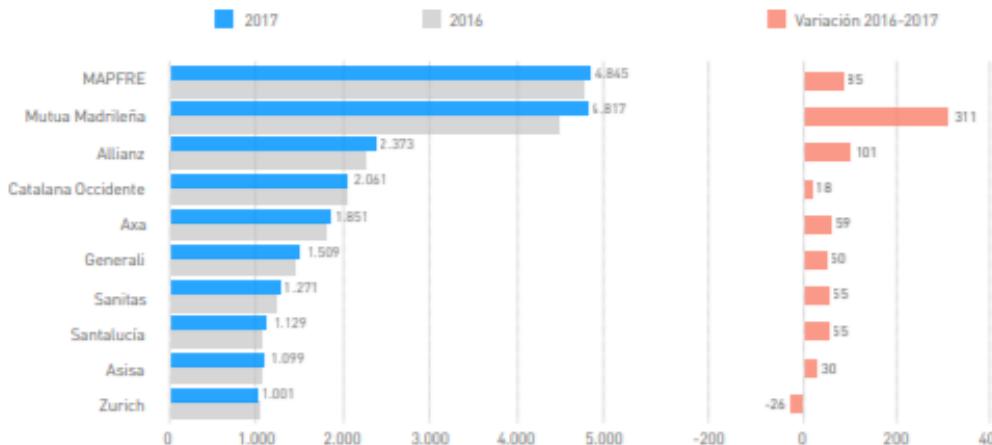
Agentes Exclusivos	Agentes Vinculados
OBS-exclusivos	OBS-vinculados
Corredores	Oficinas de la entidad
Portal de Internet	Otros Canales



Fuente: Servicio de Estudios de MAPFRE (con datos de la DGSFP)

Mercado español

Gráfica 2.2-b
España: ranking total de grupos aseguradores No Vida por volumen de primas, 2016-2017
(millones de euros)



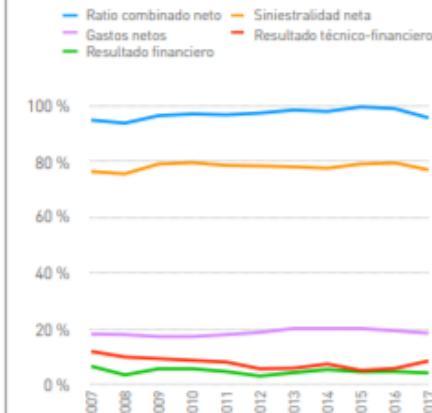
Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Tabla 3.2-b
Indicadores básicos del seguro de Automóviles,
2016-2017
(primas, millones de euros; ratio sobre primas, %)

	2016	2017
Volumen de primas emitidas (mill. de €)	10.566	10.922
Variación de primas	5,1 %	3,4 %
Retención	89,5 %	89,5 %
Siniestralidad bruta	79,0 %	76,4 %
Gastos brutos	19,5 %	18,8 %
Siniestralidad neta	79,5 %	77,0 %
Ratio combinado neto	98,9 %	95,6 %
Resultado financiero	4,9 %	4,4 %
Resultado técnico - financiero	6,0 %	8,7 %

Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Gráfica 3.2-b
Evolución del resultado del ramo de Automóviles,
2007-2017
(indicadores sobre primas)



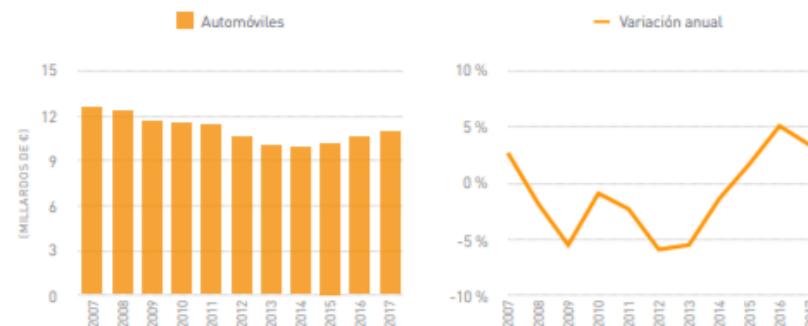
Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Fundación **MAPFRE**

EL MERCADO ESPAÑOL DE SEGUROS EN 2017

Servicio de Estudios de MAPFRE

Gráfica 3.2-a
Evolución del seguro directo de Automóviles en España, 2007-2017
(primas devengadas del seguro directo, millardos de euros; variación anual, %)



Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Mercado español

Tabla 3.2-c

Frecuencias y costes medios por garantías en el seguro de Automóviles, 2016-2017
(frecuencia, %; coste medio, euros)

Garantías	Frecuencia (%)			Coste medio (€)		
	2016	2017	% de diferencia	2016	2017	% de variación
Responsabilidad Civil	8,6 %	8,6 %	0,04 %	1.871	1.820	-2,7 %
Corporal	2,0 %	1,9 %	-0,08 %	4.970	4.856	-2,3 %
Material	7,4 %	7,4 %	0,04 %	872	879	0,9 %
Daños propios	31,5 %	30,3 %	-1,20 %	713	734	3,0 %
Rotura lunas	6,4 %	6,4 %	0,00 %	290	291	0,3 %
Robo	0,8 %	0,8 %	-0,02 %	916	968	5,7 %
Defensa jurídica	1,7 %	1,7 %	0,01 %	279	278	-0,3 %
Ocupantes	0,2 %	0,3 %	0,06 %	1.265	1.249	-1,3 %
Incendios	0,1 %	0,1 %	0,05 %	2.977	3.023	1,5 %
Retirada carnet	0,0 %	0,0 %	-0,02 %	940	805	-14,3 %

Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

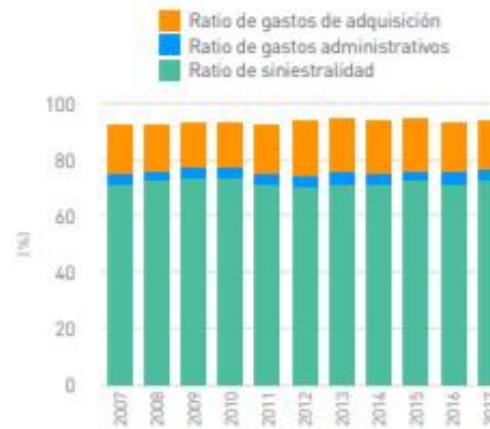
Tabla 3.1-f

Indicadores básicos del seguro de No Vida, 2016-2017
(primas, millones de euros; ratio sobre primas, %)

	2016	2017
Volumen de primas emitidas (millones €)	32.693	34.003
Variación de primas	4,5 %	4,0 %
Retención	84,8 %	84,9 %
Siniestralidad bruta	68,9 %	71,0 %
Gastos brutos	22,6 %	22,3 %
Siniestralidad neta	71,3 %	72,0 %
Ratio combinado neto	93,6 %	94,0 %
Resultado financiero	3,9 %	3,5 %
Resultado técnico - financiero	10,3 %	9,5 %

Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Gráfica 3.1-d
Evolución del ratio combinado No Vida, 2007-2017
(ratio combinado total, %; cambio anual del ratio combinado, pp)



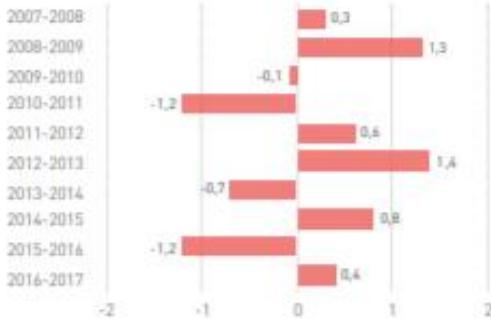
Fuente: Servicio de Estudios de MAPFRE (con datos de ICEA)

Fundación **MAPFRE**

EL MERCADO ESPAÑOL DE SEGUROS EN 2017

Servicio de Estudios de MAPFRE

Cambio anual en el ratio combinado (pp)



Mercado español

PRINCIPALES MAGNITUDES

	2014	2015	2016
Mutualistas	978.968	967.902	933.222
Pólizas de cartera	1.495.240	1.521.421	1.497.115
Primas emitidas*	401.557	417.708	379.183
Resultado*	3.821	3.108	2.498
Fondos propios*	347.502	349.905	343.812

* Miles de euros



Naturaleza del gasto (en miles de euros)



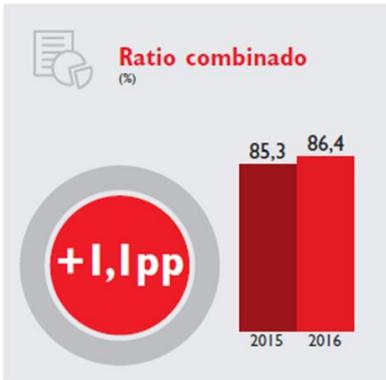
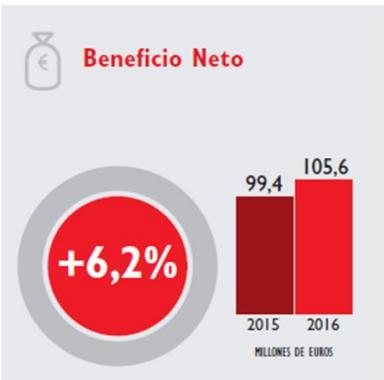
En su conjunto el ratio combinado de la Entidad, que engloba la siniestralidad más los gastos de gestión, se ha situado en el 104,34%, superior al 103,81% obtenido un año antes. Este incremento ha sido motivado por un incremento en el ratio de gastos. Este aumento es consecuencia de la disminución de primas totales por la cesión del negocio agrario a Agropelayo, S.A., ya que, como se decía con anterioridad, la cifra nominal de gastos se ha reducido en este ejercicio en 8,3 millones de euros. Del mismo modo, una menor activación de los gastos, vinculado con la disminución de la prima periodificada, completan la explicación a este aumento en el ratio.

Evolución del ratio combinado total

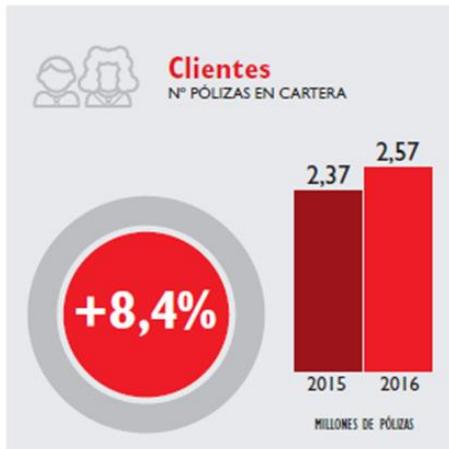
	2014	2015	2016
Siniestralidad	70,07%	71,30%	70,67%
Gastos de gestión	32,92%	32,51%	33,67%
Ratio combinado	102,99%	103,81%	104,34%

Mercado español

Principales datos del año 2016



linea directa



En 2016, el volumen de primas devengadas del Grupo Línea Directa ha alcanzado los 738,7 millones de euros, el más alto de toda su historia.

Además, ha superado los 2,5 millones de clientes y se ha afianzado como una de las aseguradoras españolas más rentables y eficientes del sector.



¿Por qué tenemos que entender la tendencias del mercado?



FINANCIAL [THINKING]

¿Cuál es el precio de nuestro producto?

¿Cuál es el coste de nuestro producto?

Diferencias entre la universidad y la vida real

¿Qué buscamos de nuestros modelos?

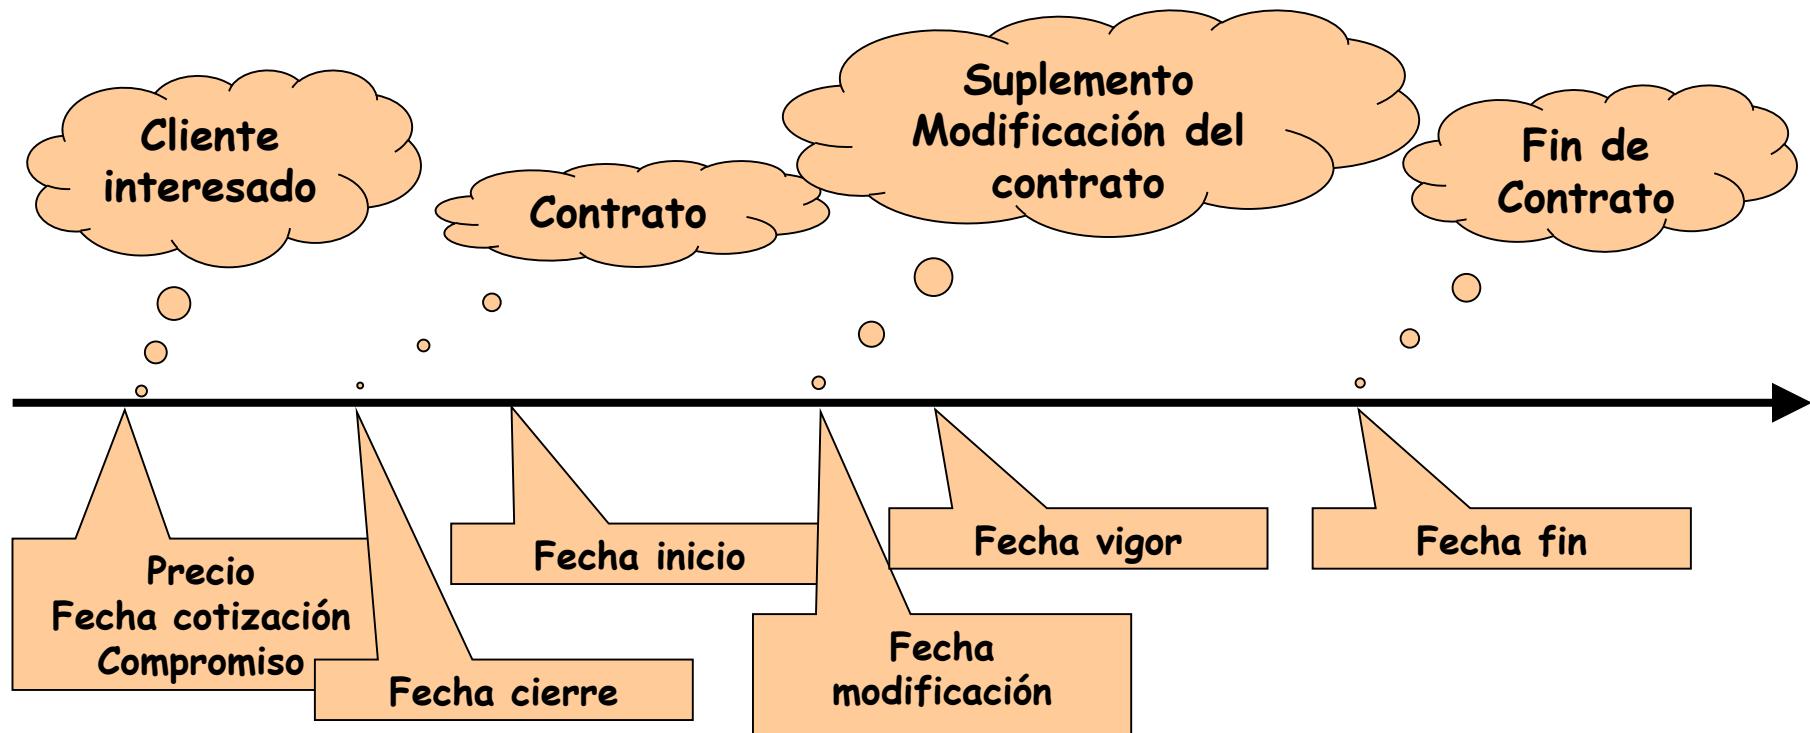
Compañía de Seguros

Universidad

La base: ¿Qué datos tenemos disponibles?

Póliza – factores (cuestionario) y fechas

- ✓ Solo podemos utilizar en los modelos lo que hay





Factores



Residencia

CPostal
Provincia
Factores socio-demograficas



Vehículo

Edad
Carne
Sexo
2º Conductor
Uso
Forma de Pago
Producto
Bonificación

Antigüedad
Precio
Combustible
Potencia
Peso
Cilindrada
Pesopotencia
Remolque
Puertas
Segmento
Clase
Velocidad
Marca/Modelo/Versión



Externos

- Experian
- Importe
 - Origen
 - Score Global
 - Nota Global

SINCO

Estimación del Riesgo



Estimación Riesgo – Seguro Automóvil

Uso de GLM. Introducción

El diagrama que se muestra a continuación muestra las principales fases de un modelo de precio segmentado utilizando modelos GLM:



Estimación Riesgo – Seguro Automóvil

Uso de GLM

A modo resumen:

Modelos GLM

Los modelos GLM son modelos de regresión en donde la variable dependiente no siempre se comporta como una distribución normal, sino que puede ser ajustada a cualquier distribución de la familia de distribuciones exponenciales.

Para modelos de salud es muy habitual el uso de modelos Tweedie (modelar la prima pura directamente).

Significancia de las variables:

Algo importante a tener en cuenta en la interpretación de los resultados es la aportación de cada una de las variables e interacciones al modelo. Dicha aportación se puede observar mediante el análisis del indicador conocido como p-valor (asignado a cada uno de los estimadores).

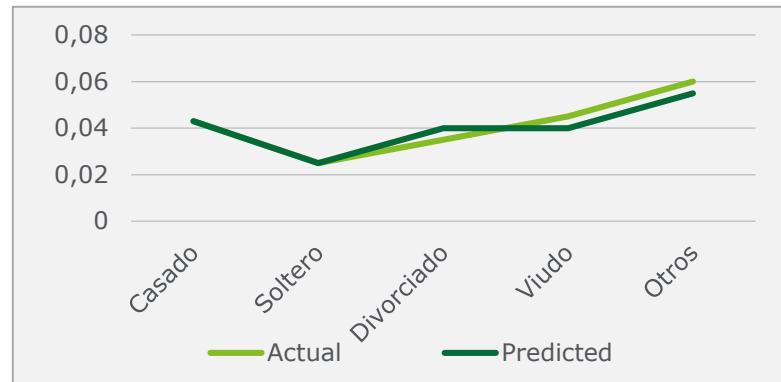
Asimismo, se analizan los intervalos de confianza de las variables dentro del modelo.

Significancia del modelo

Para obtener un mejor modelo de estimación, es conveniente hacer comparaciones entre los distintos modelos iterados observando sus criterios de información.

Est_Civil (Transformations Group)

Ilustrativo



Ilustrativo

Setting/Statistic	Value			
Profiles in Sample	339			
Mean Actual Response	0.0106101			
Mean Predicted Response	0.0131586			
Regression Model	Gamma Log Reg	β	Std Err	χ^2
Variables Required		-1.1845	0.191	38.3
Null model -2log(L)		-0.75389	0.179	17.7
Model -2log(L)		0.70282	0.438	2.57
Chi-Square (χ^2)		1.4828	0.473	0.10892
p-value				
Akaike IC		-3,044.2		
Bayesian IC		-2,983		

Otras capacidades de modelización

Durante la fase de diseño del modelo de proyección podrían surgir la posible utilización de otros modelos distintos a modelos GLM.

GLM – teoría de la estadística general (no de seguros)
(1972 NOLDER & WEDDERBURN)

Muy desarrollado (Aplicaciones/Universidades)

Se usan en muchos ramos/ áreas – no solo en seguros
Amplias posibilidades de aprender

Amplio espectro de Standard Software
(SAS, Matlab, R, ...)

Modelo Prima pura (prima de riesgo) con un punto de masa en cero (tweedy – regresión)

Vs.

Modelos de Frecuencia * Modelo de costes con sus distribuciones correspondientes

Software ofrece algoritmos automáticos

forward

backward

stepwise

→ ya no se usan ¿?

ii CREAR UNA TARIFA ES ARTE !!

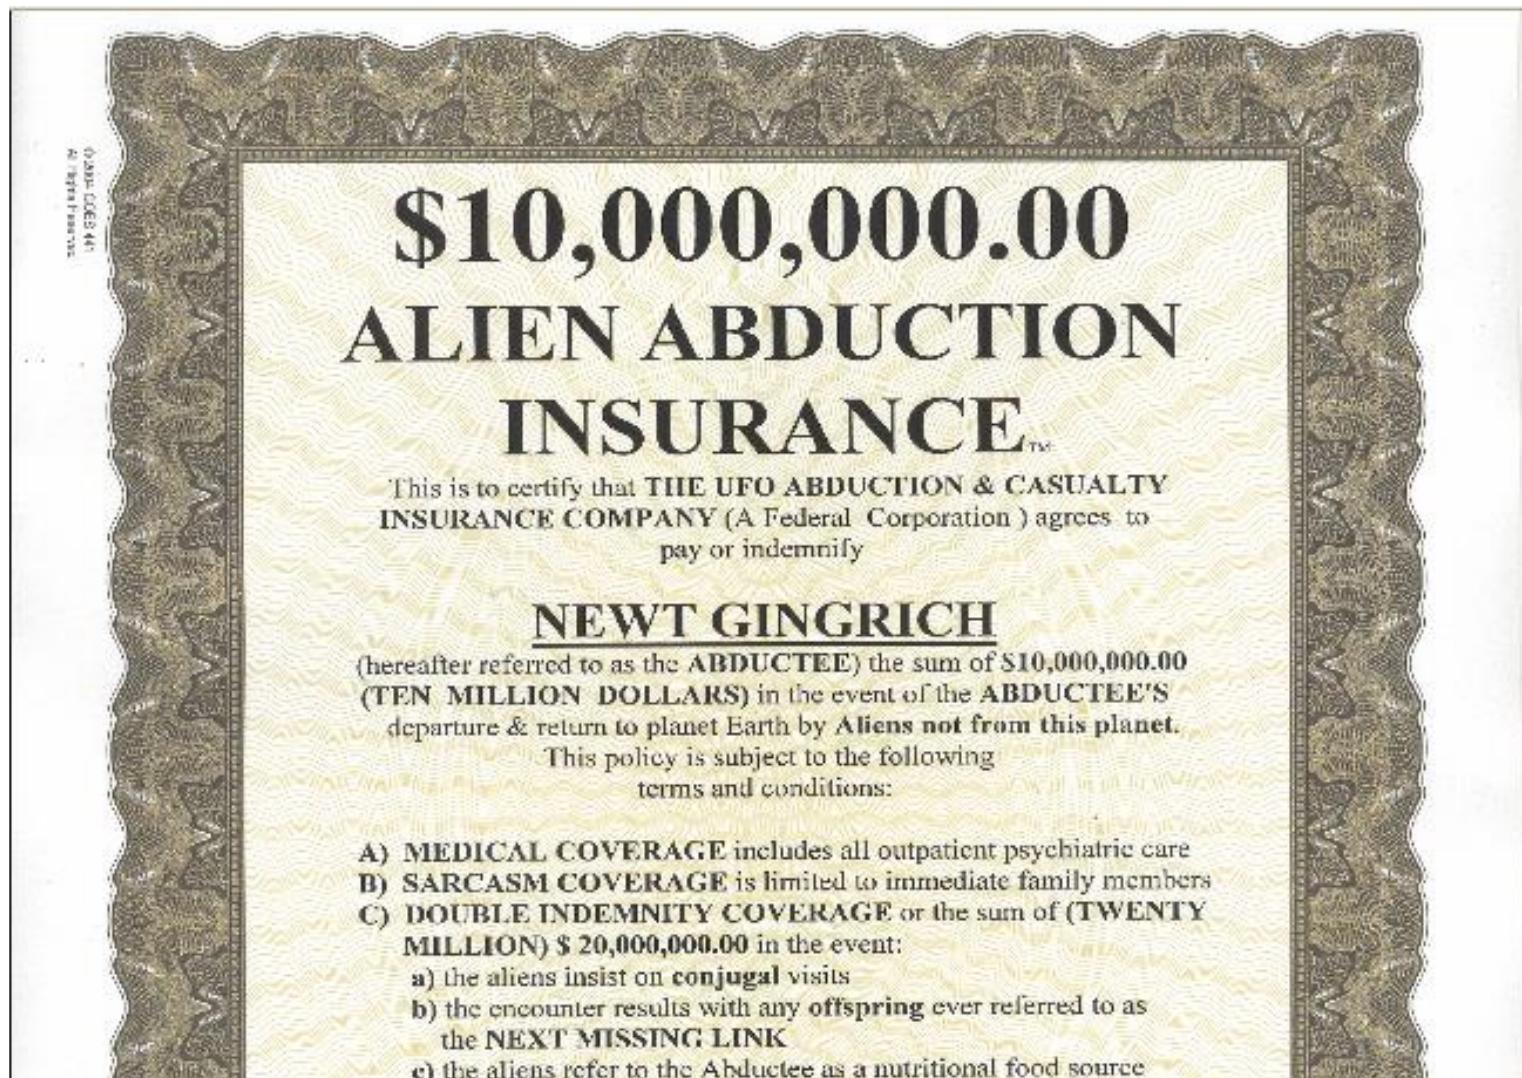
Prima final

= estimación de los **futuros** siniestros
+ Seguridad (~ 4%)
+ Gastos (~ 10-40%)
+ Beneficios
+ Impuestos (~ 6,..% + fijo)

Pero sólo tenemos (podemos realizar) un modelo sobre los siniestros **pasados**.

Conclusiones:

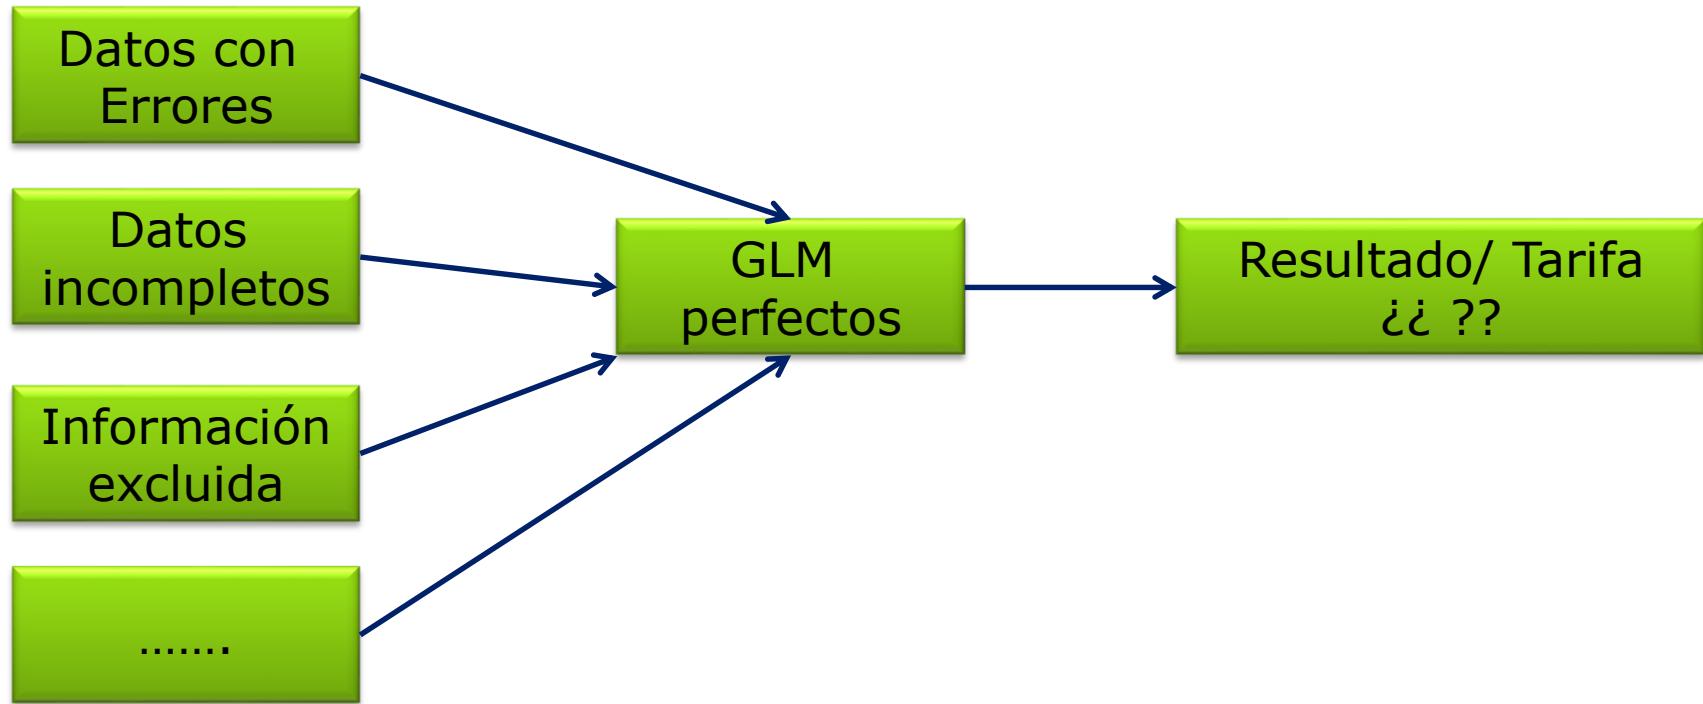
- ✓ No buscamos una descripción perfecta del pasado
- ✓ Buscamos la parte que se va a repetir
- ✓ Buscamos tendencias
- ✓ Buscamos reglas
- ✓ La misma base/producto



C. GLM en seguros

GLM en seguros

Preparación de los datos:



GLM en seguros



FINANCIAL [THINKING]

Factores de riesgo:

Factores a priori

Cuestionario

objetivo

subjetivo

Sobre la persona

Sobre el objeto (coche)

Sobre la Región

Te subimos/bajamos la prima porque te “pareces” a alguien que suele tener muchos siniestros.

Se usa la información **ANTES** de empezar a conducir

Factores de riesgo:

Factores a priori

subjetivo

UK: 30 Millones de vehículos pero

2011: 2.000 Millones de cotizaciones en agregadores

Estudio: kms anuales

Conductor > 60 años	20.000 kms	→	Freq = 1
	5.000 kms	→	Freq = 0.9

Conductor < 40 años	20.000 kms	→	Freq = 1
	5.000 kms	→	Freq = 1.2

Factores de riesgo:

Factores a priori

Hay tendencias a limitar el uso de los factores a priori

Regulador

sex (EU: 21/12/2012; EE.UU.)
edad (EE.UU.)

Organizaciones de consumidores
información socio-económica

Factores de riesgo:

Factores de experiencia

Experiencia propia

En la compañía

En otras C.

- ✓ Bonus / Malus
- ✓ Sinco
- ✓ Información interna sobre el cliente (CRM)

Te subimos/bajamos la prima porque "tú" en los últimos años ...

La base es el número de siniestros pasados del individuo.

GLM en seguros



FINANCIAL [THINKING]

Factores de riesgo:

- ✓ Bonus / Malus
- ✓ Sinco

Información incompleta sobre siniestros pequeños (no se reportan a la compañía para no perder bonificación)

Encontrar el balance entre:

Conductores buenos con mala suerte

Realmente malos conductores

¿Cadenas Markov?

GLM en seguros



FINANCIAL [THINKING]

Factores de riesgo:

Desde el punto de vista actuarial no hacen faltar tantos factores.
Es por la competencia → encontrar la más mínima ventaja

A veces con consecuencias sociales para “malos conductores”
(o los que se parecen a ellos)

Declaración no correcta del riesgo puede provocar la perdida de cobertura → (prácticamente ya no se aplica)

BUTLER (1993) ya ha propuesto tarificar por exposición en kms en lugar de en años.

GLM – Modelos Frecuencia



FINANCIAL [THINKING]

La distribución para un individuo de tener un siniestro es Poisson.

Poisson

$$P = \text{Poi}(\lambda)$$

$$P\{k\} = \lambda^k \exp(-\lambda) / k!$$

$$\mu_1(P) = \lambda, \text{Var}(P) = \lambda$$

Link función:

ident.	→ resultado es una tarifa aditiva
log.	→ resultado es una tarifa multiplicativa

¡El resultado es distinto!

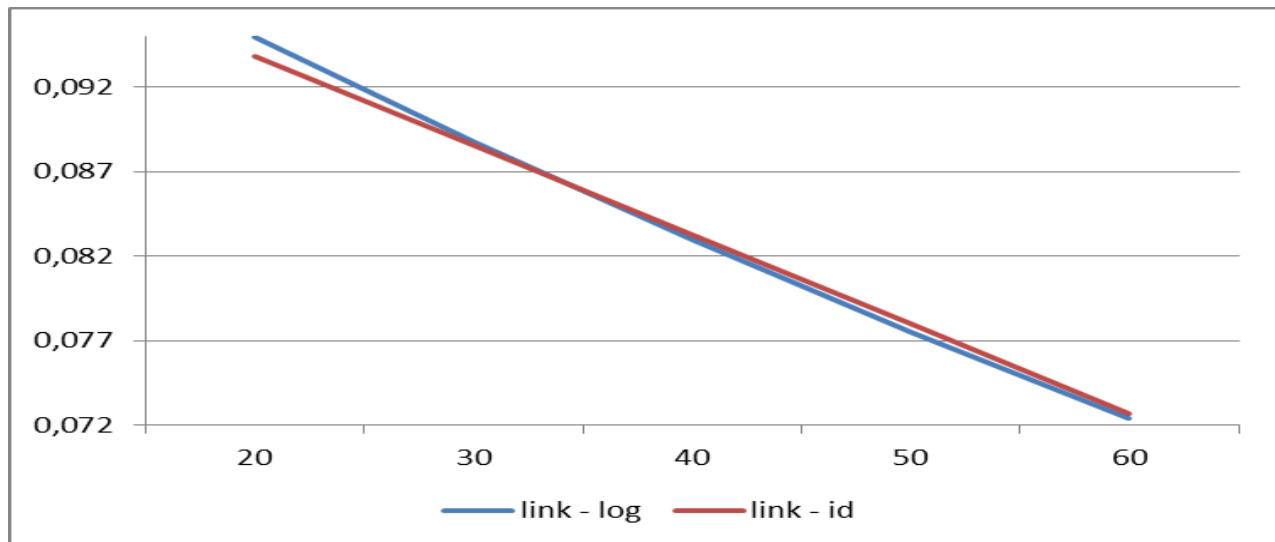
Canonical link función – hacer los cálculos numéricos más fácil
(ya no es relevante)

GLM – Modelos Frecuencia

Link función: ident. → resultado es una tarifa aditiva
log. → resultado es una tarifa multiplicativa

Resultado en R – en un caso simple:

```
glm(data=pol, formula = Siniestros ~ Edad, family = poisson(link = "log"), weights=Expuestos)
Call: glm(formula = Siniestros ~ Edad, family = poisson(link = "log"), data = pol, weights = Expuestos)
Coefficients: (Intercept) Edad -2.218541 -0.006782
Degrees of Freedom: 48573 Total (i.e. Null); 48572
Residual Null Deviance: 9364
Residual Deviance: 9352
AIC: 12780
glm(data=pol, formula = Siniestros ~ Edad, family = poisson(link = "identity"),weights=Expuestos)
Call: glm(formula = Siniestros ~ Edad, family = poisson(link = "identity"), data = pol, weights = Expuestos)
Coefficients: (Intercept) Edad 0.1043943 -0.0005286
Degrees of Freedom: 48573 Total (i.e. Null); 48572
Residual Null Deviance: 9364
Residual Deviance: 9353
AIC: 12780
```



GLM – Modelos Frecuencia

agrupado → 8 grupos
polinomial → de orden 1 ,2 y 3
Resultado en R – en un caso simple:

```
glm(data=pol, formula = Siniestros ~ Edad + Edad_q + Edad_c, family = poisson(link = "log"),  
weights=Expuestos)
```

```
Coefficients: (Intercept) Edad Edad_q Edad_c  
-9.778e-01 -9.534e-02 1.945e-03 -1.325e-05
```

Degrees of Freedom: 48573 Total (i.e. Null); 48570

Residual Null Deviance: 9364

Residual Deviance: 9348

AIC: 12780

```
> glm(data=pol, formula = Siniestros ~ Edad_fmt, family = poisson(link = "log"),  
weights=Expuestos)
```

```
Coefficients: (Intercept) Edad_fmtB.21-24 Edad_fmtC.25-29 Edad_fmtD.30-34  
-2.1458 -0.1117 -0.2563 -0.3970  
Edad_fmtE.35-39 Edad_fmtF.40-49 Edad_fmtG.50-59 Edad_fmtH.>60  
-0.3646 -0.3128 -0.4104 -0.5068
```

Degrees of Freedom: 48573 Total (i.e. Null); 48566

Residual Null Deviance: 9364

Residual Deviance: 9344

AIC: 12790

GLM – Modelos Frecuencia

Comparar modelos - ¿Qué modelo es mejor?

df versus error

Explicar la variables de respuesta sólo con los variables necesarios

Muchas variables → “good fit”, pero los parámetros (estimates) tienen poca precisión (alta desviación)

Pocas variables → “less good fit”, pero en este caso los parámetros (estimates) tienen una alta precisión (baja desviación)

Por eso se crean criterios para buscar el equilibrio entre la reducción del error y el número de los parámetros (penalty)

GLM – Modelos Frecuencia



FINANCIAL [THINKING]

Comparar modelos - ¿Qué modelo es mejor?

AIC – Akaike's Information Criterion

$$AIC = -2I + 2p = S/\sigma^2 + 2p$$

BIC - Bayesian Information Criterion

$$BIC = -2I + p \ln n = S/\sigma^2 + p \ln n$$

Para seguros con muchas observaciones n con el criterio BIC los parámetros se castigan mucho y salen modelos demasiado simples.

Es recomendable usar AIC.

GLM – Modelos Frecuencia

Explicar los costes de los siniestros con los factores de Riesgo

Hay muchos factores importantes fuera de la observación:

- reflejos
- costumbre (consumo de alcohol, fiestas, ...)
- respeto a las señales/reglas de tráfico



muchas variabilidad dentro de las celdas.

Overdispersión: $\text{Var}(P) >> E(P)$

– Para la frecuencia - Número de siniestros por póliza

Si lo ignoramos creamos unos intervalos de confianza estrechos con todas las consecuencias.

Poisson

$P = \text{Poi}(\lambda)$

$P\{k\} = \lambda^k \exp(-\lambda)/k!$

$\mu_1(P) = \lambda, \text{Var}(P) = \lambda$

Neg. Binomial

$P = \text{Nbin}(r,p)$

$P\{k\} = \frac{(r+k-1)}{k} p^r (1-p)^k, r>0, 0<p<1$

$\mu_1(P) = \frac{r(1-p)}{p} < \frac{r(1-p)}{p^2} = \text{Var}(P)$

GLM – Modelos Frecuencia

Overdispersión: $\text{Var}(P) >> E(P)$

En cada celda tenemos individuos Poisson (λ)

pero λ no es fijo, tiene una distribución Gamma.

La distribución conjunta es una

Neg. Binomial

Pólizas	1000	1000
0 siniestros	800	800
1 siniestro	180	150
2 siniestros	18	40
3 siniestros	2	10

	$\mu()$	$\text{Var}()$
	1000	0,222 0,221
0	800	0,222 0,05
1	180	0,222 0,61
2	18	0,222 3,16
3	2	0,222 7,72

	$\mu()$	$\text{Var}()$
	1000	0,260 0,332
0	800	0,260 0,07
1	150	0,260 0,55
2	40	0,260 3,03
3	10	0,260 7,51

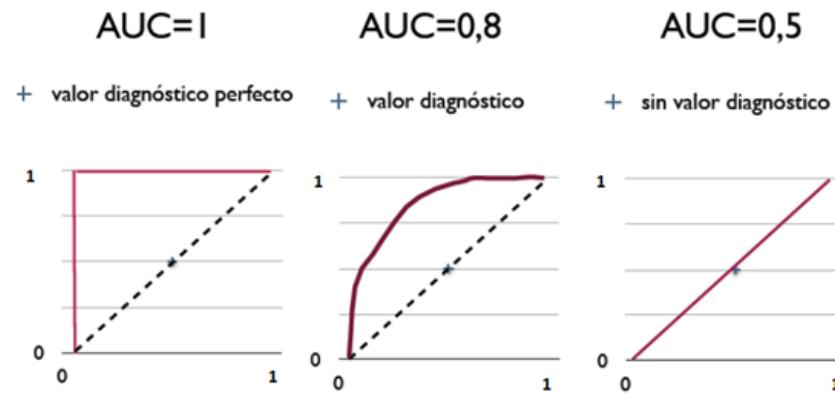
GLM – Modelos Frecuencia

CASO Especial: 0,1 Bernoulli (casos históricos del siglo XVIII)

→ Regresión logística $g(\mu) = \ln \frac{\pi}{1-\pi} = x'\beta$

→ Tablas de clasificación 2 x 2 (en función de un nivel para la predicción)

→ Curvas ROC (Receiver operating Characteristics)



→ logit -link: $\ln \frac{\pi}{1-\pi}$

(que crea una variable que siempre está entre 0,1)

GLM – Modelos Frecuencia

CASO Especial: 0,1 Bernoulli (casos históricos del siglo XVIII)

- Regresión logística $g(\mu) = \ln \frac{\pi}{1-\pi} = x'\beta$
- Tablas de clasificación 2 x 2 (en función de un nivel para la predicción)

Nivel = 0.08	Sin siniestro	Siniestro	
Sin siniestro (real)	5.400	900	6.300
Siniestro (real)	370	90	460
	5.770	990	6.760

Sensitivity: predicción correcta de un siniestro

$90/460=0,195$

Specificity: predicción correcta de "sin siniestro"

$5400/6300=0,857$

GLM – Modelos Costes

- Para el coste/importe por siniestro (modelo individual)

Gamma:

$$F(x) = P(X \leq x) = \begin{cases} \frac{\alpha^p}{\Gamma(p)} \int_0^x x^{p-1} \cdot e^{-\alpha x} dx, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

p=1 → distribución exponencial

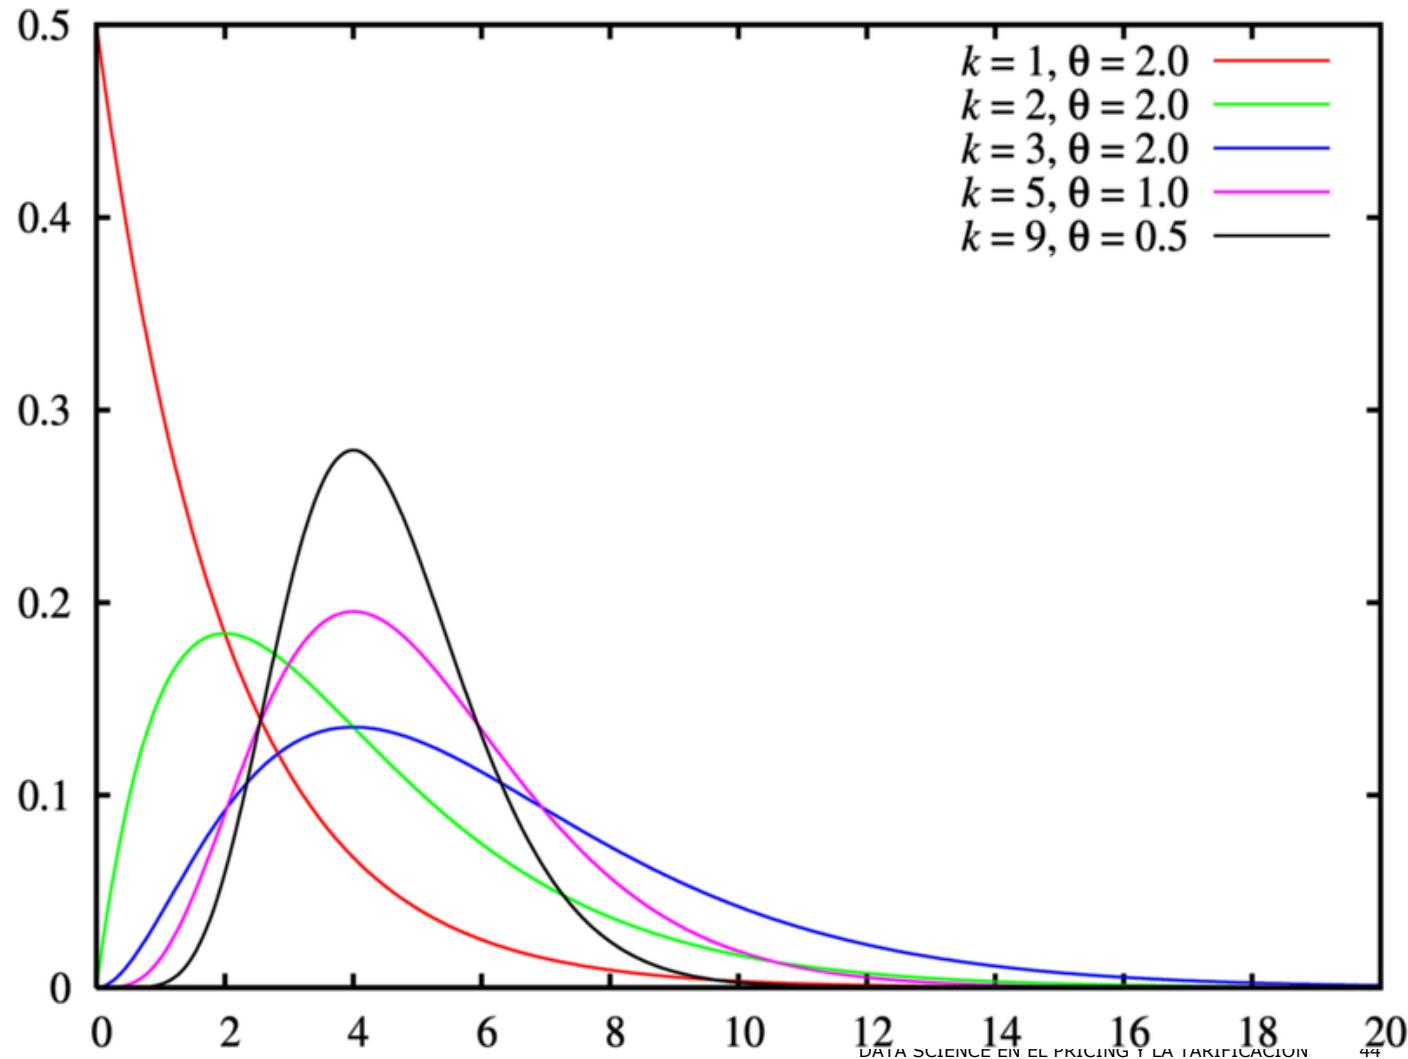
Distribución: log-normal (modelo colectivo)

Si $X \sim N(\mu, \sigma^2)$ entonces $\exp(X) \sim \text{Log-N}(\mu, \sigma^2)$

¡No es de la familia de las distribuciones exponenciales!

GLM – Modelos Costes

- Para el coste medio – importe por siniestro



GLM – Modelos Costes



FINANCIAL [THINKING]

Explicar los costes de los siniestros con los factores de Riesgo

Gauss inversa:

$$f(x; \mu, \lambda) = \left[\frac{\lambda}{2\pi x^3} \right]^{1/2} \exp \frac{-\lambda(x - \mu)^2}{2\mu^2 x}$$

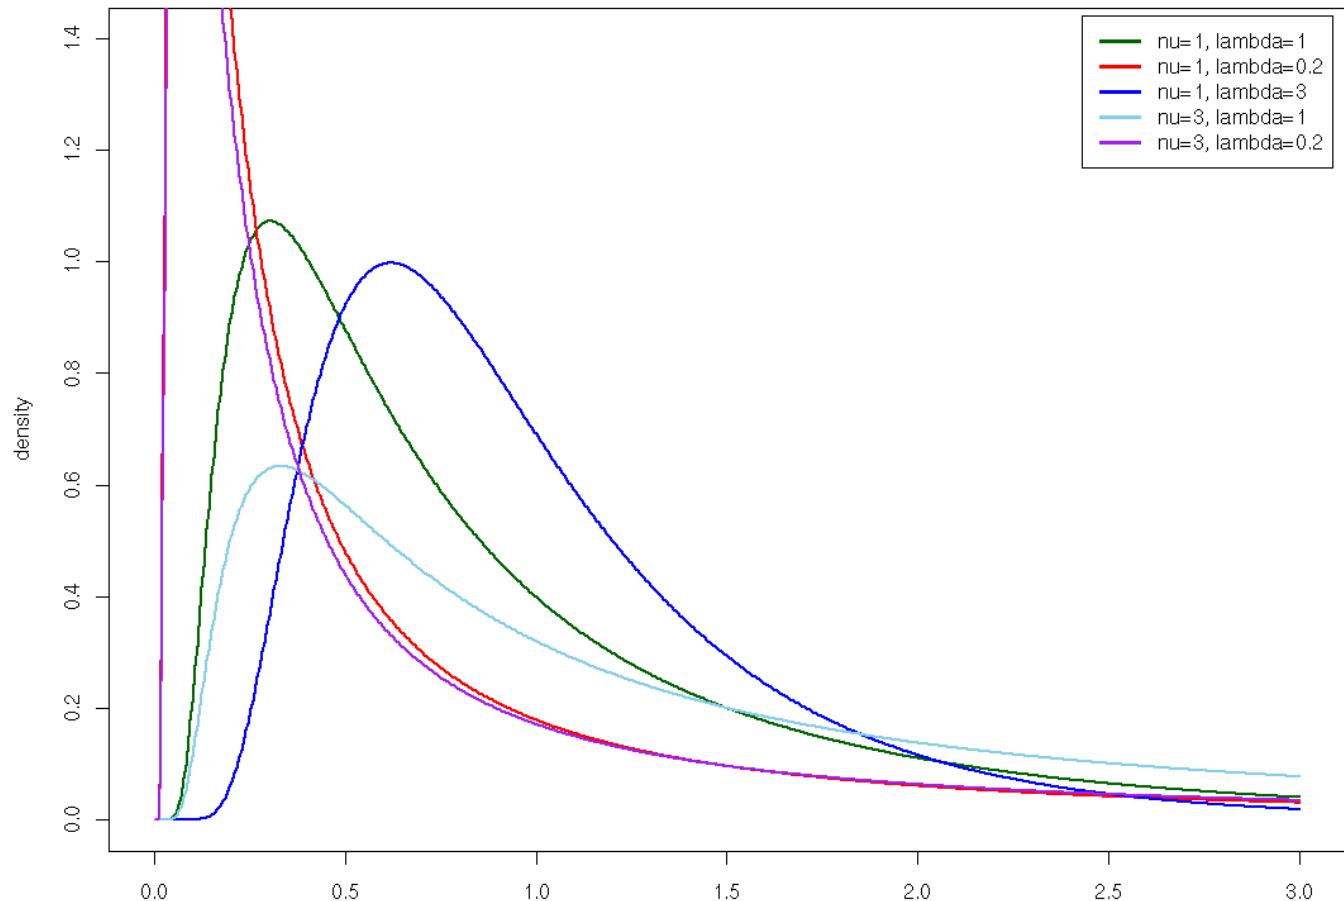
Varianza $\approx \mu^3$

(para la distribución Gamma $\approx \mu^2$)

A veces hay casos que la Gauss inv. se adapta mejor a los datos pero no converge.

GLM – Modelos Costes

Explicar los costes de los siniestros con los factores de Riesgo



Selección de los factores individuales:

¿Qué es el mejor modelo para GLM?

UNIVERSIDAD

- Explicar el comportamiento de los datos (pasados) con las menos variables posibles
- Evitar redundancia
- Minimizar error

¿Qué es el mejor modelo para un actuario?

COMPAÑÍA SEGUROS

- Explicar el comportamiento de los datos (futuros) con todas las variables disponibles
- Consistencia en el tiempo
- Comportamiento explicable y lógico
- Descubrir oportunidades
- Minimizar error
- Se adapta a nuestros sistemas IT

GLM – en Seguros

Prima de riesgo lunas:

$$\begin{aligned} &= \text{frecuencia} * \text{coste medio} \\ &= 0,0548 * 317,158 \\ &= 17,37 \end{aligned}$$

Prima de riesgo RC:

$$\begin{aligned} &= \text{frecuencia}_{\text{RCMat_culpa}} * 882 \\ &+ \text{frecuencia}_{\text{RCCorp}} * \text{coste medio}_{\text{RCCorp}} * \text{LargeClaims} \\ &+ \text{frecuencia}_{\text{RCMat_inoc}} * \{ (882 + \text{coste medio}_{\text{RCMat_inoc}}) - 882 \} \end{aligned}$$

¿Cuál es nuestro “rate” final?

Intercept		1	-2,960	0,052
EDAD	1.<20	1	0,417	1,517
EDAD	2.21-24	1	0,0983	1,103
EDAD	3.25-28	1	-0,0143	0,986
EDAD	4.29-32	1	-0,1764	0,838
EDAD	5.33-40	1	-0,4666	0,627
EDAD	6.41-50	1	-0,3829	0,682
EDAD	7.51-60	1	-0,3084	0,735
EDAD	8.>60	1	-0,9232	0,397

Intercept		1	5,935	378,191
EDAD	1.<20	1	-0,3504	0,704
EDAD	2.21-24	1	-0,1799	0,835
EDAD	3.25-28	1	-0,1539	0,857
EDAD	4.29-32	1	-0,1095	0,896
EDAD	5.33-40	1	-0,0869	0,917
EDAD	6.41-50	1	0,0081	1,008
EDAD	7.51-60	1	-0,1187	0,888
EDAD	8.>60	0	0	1,000

AJUSTAR y INTERPRETAR LOS MODELOS (Simulaciones)

✓ Mejorar el modelo

- smoothing (suavizar algunos efectos)
- restricciones/limitaciones
- sentido común

✓ Interpretar los resultados

- simulaciones
- impacto en el negocio



LOG IN | MY PROFILE | STORE | TOOLS | CONTACT US | Search |      

CAS CASUALTY ACTUARIAL SOCIETY

About Us | Membership | Future Fellows | CAS Student Central | Be An Actuary | Press Room | Advertising

EXAMS & ADMISSIONS PROFESSIONAL EDUCATION PROFESSIONALISM COMMUNITY CALENDAR PUBLICATIONS RESEARCH PRACTICE AREAS CAREER CENTER



PRESS ROOM

[HOME](#) | [PRESS ROOM](#) |
"BASIC RATEMAKING" BY GEOFF WERNER AND CLAUDINE MODLIN IS RELEASED

"BASIC RATEMAKING" BY GEOFF WERNER AND CLAUDINE MODLIN IS RELEASED

09/10/2009 —

The Casualty Actuarial Society has released "[Basic Ratemaking](#)" as a comprehensive resource for practicing actuaries and actuarial candidates.

Geoff Werner and Claudine Modlin of EMB America, LLC were the principal authors of the text which consolidates numerous syllabus papers on the topic. The CAS Executive Council first approved "Basic Ratemaking" for use on the 2010 CAS Exam 5 syllabus.

 Casualty Actuarial Society
Basic Ratemaking

 [PRINT](#)  [SHARE](#)

Related Updates

03/14/2019 [Media Advisory: Casualty Actuarial Society \(CAS\) Ratemaking, Product and Modeling \(RPM\) Seminar & Live Stream Sessions](#)

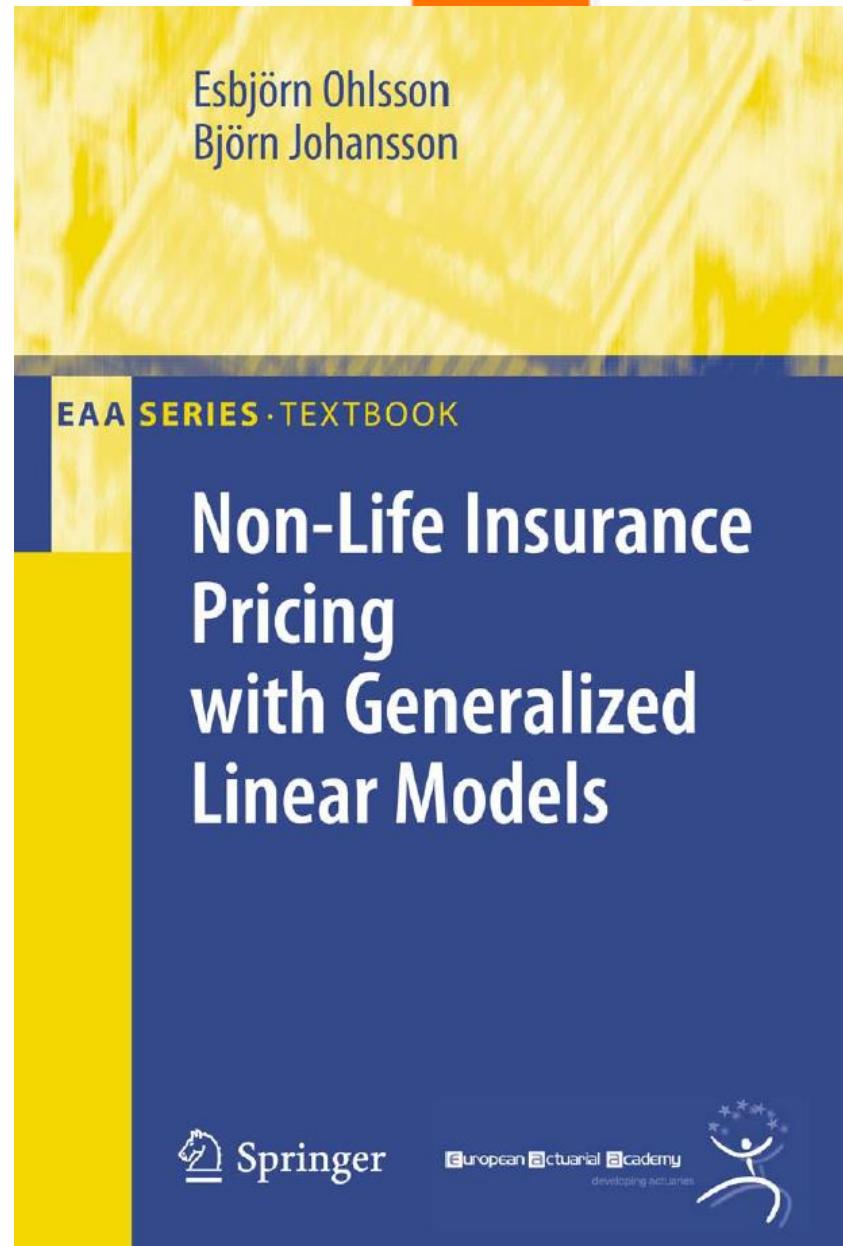
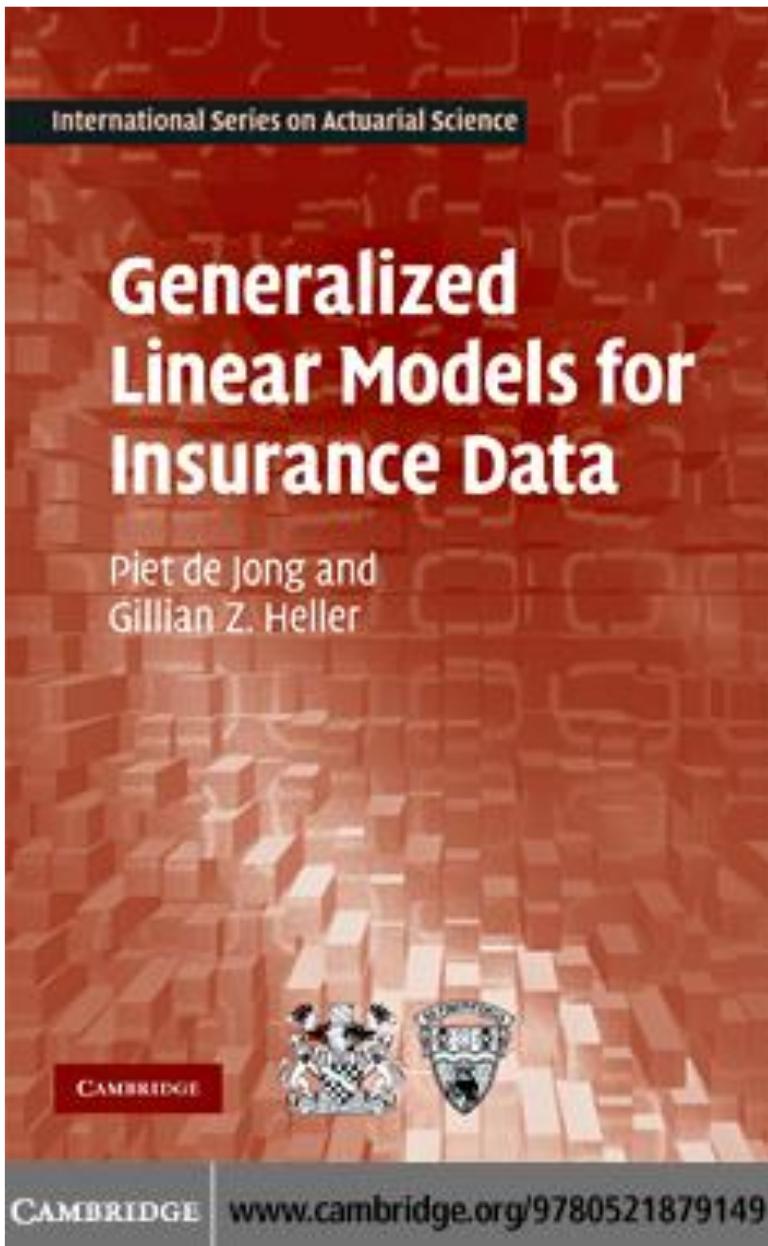
11/14/2018 [James K. Christie Begins Term as President of the Casualty Actuarial Society](#)

11/07/2018 [Casualty Actuarial Society Hires Ken Williams, FCAS, as Chief Executive Officer](#)

GLM – en Seguros

CUNEF
COLEGIO UNIVERSITARIO DE
ESTUDIOS FINANCIEROS

FINANCIAL [THINKING]

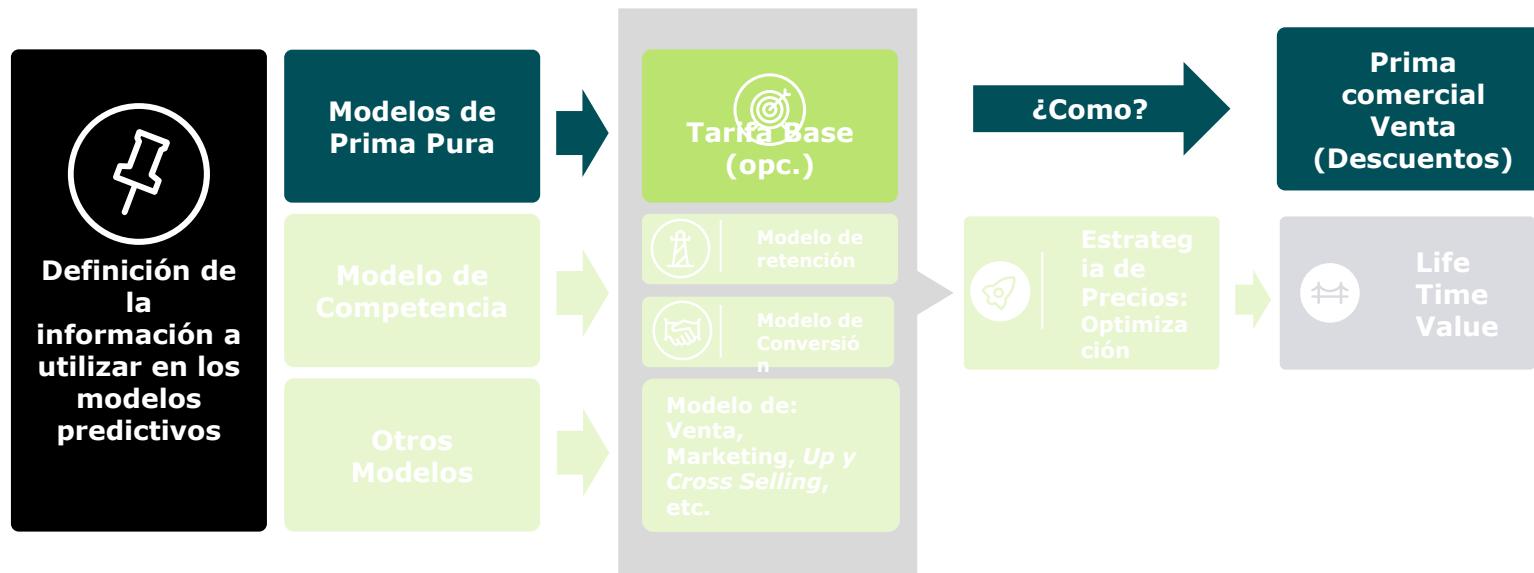


E. Modelos tradicionales (avanzados)

Modelos avanzados

Modelos de pricing Enfoque Metodológico

Estándar actual en el mercado

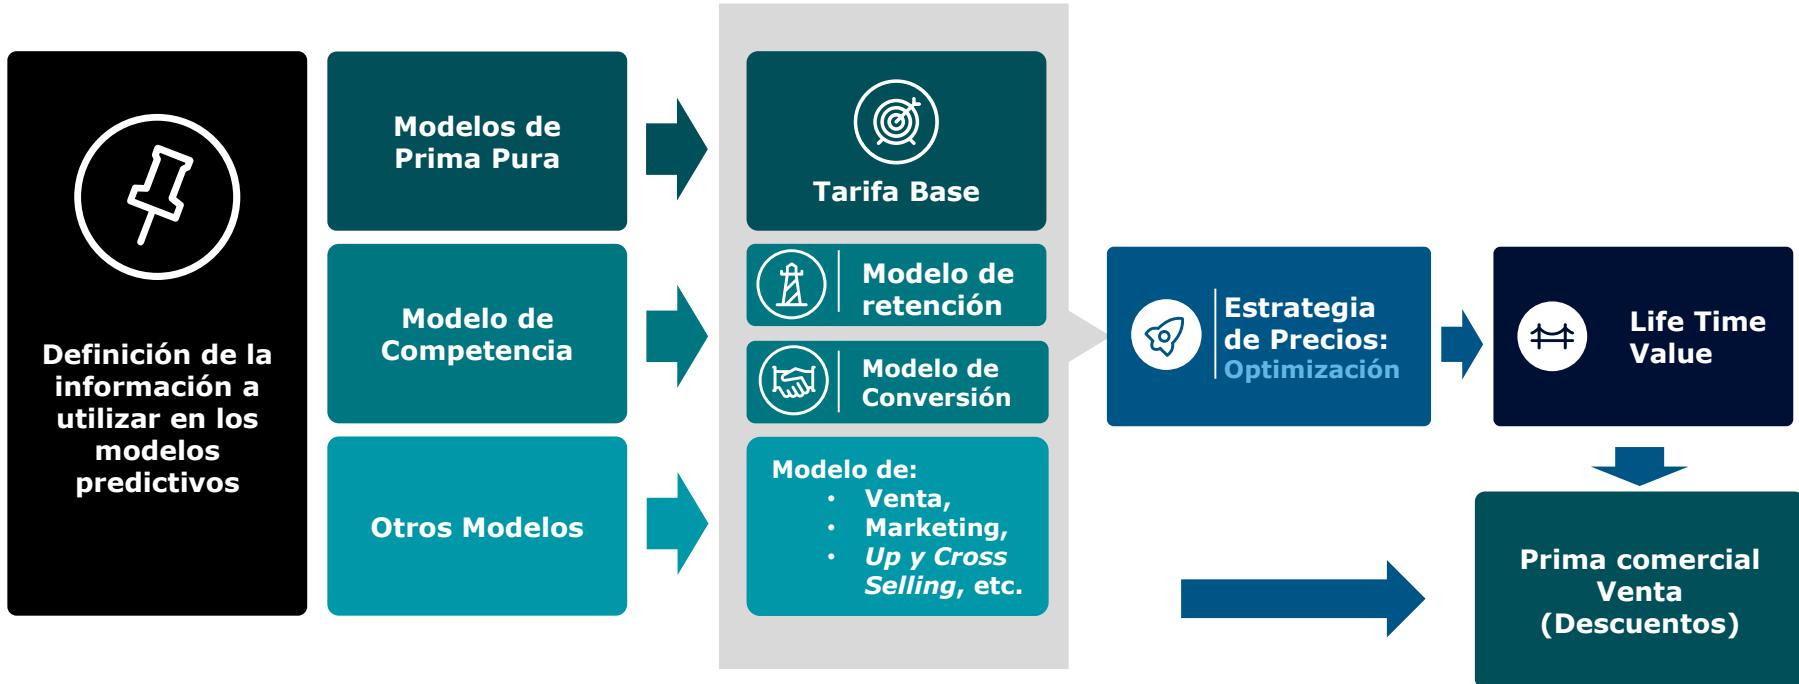


Conclusión: Mejorable

Modelos avanzados

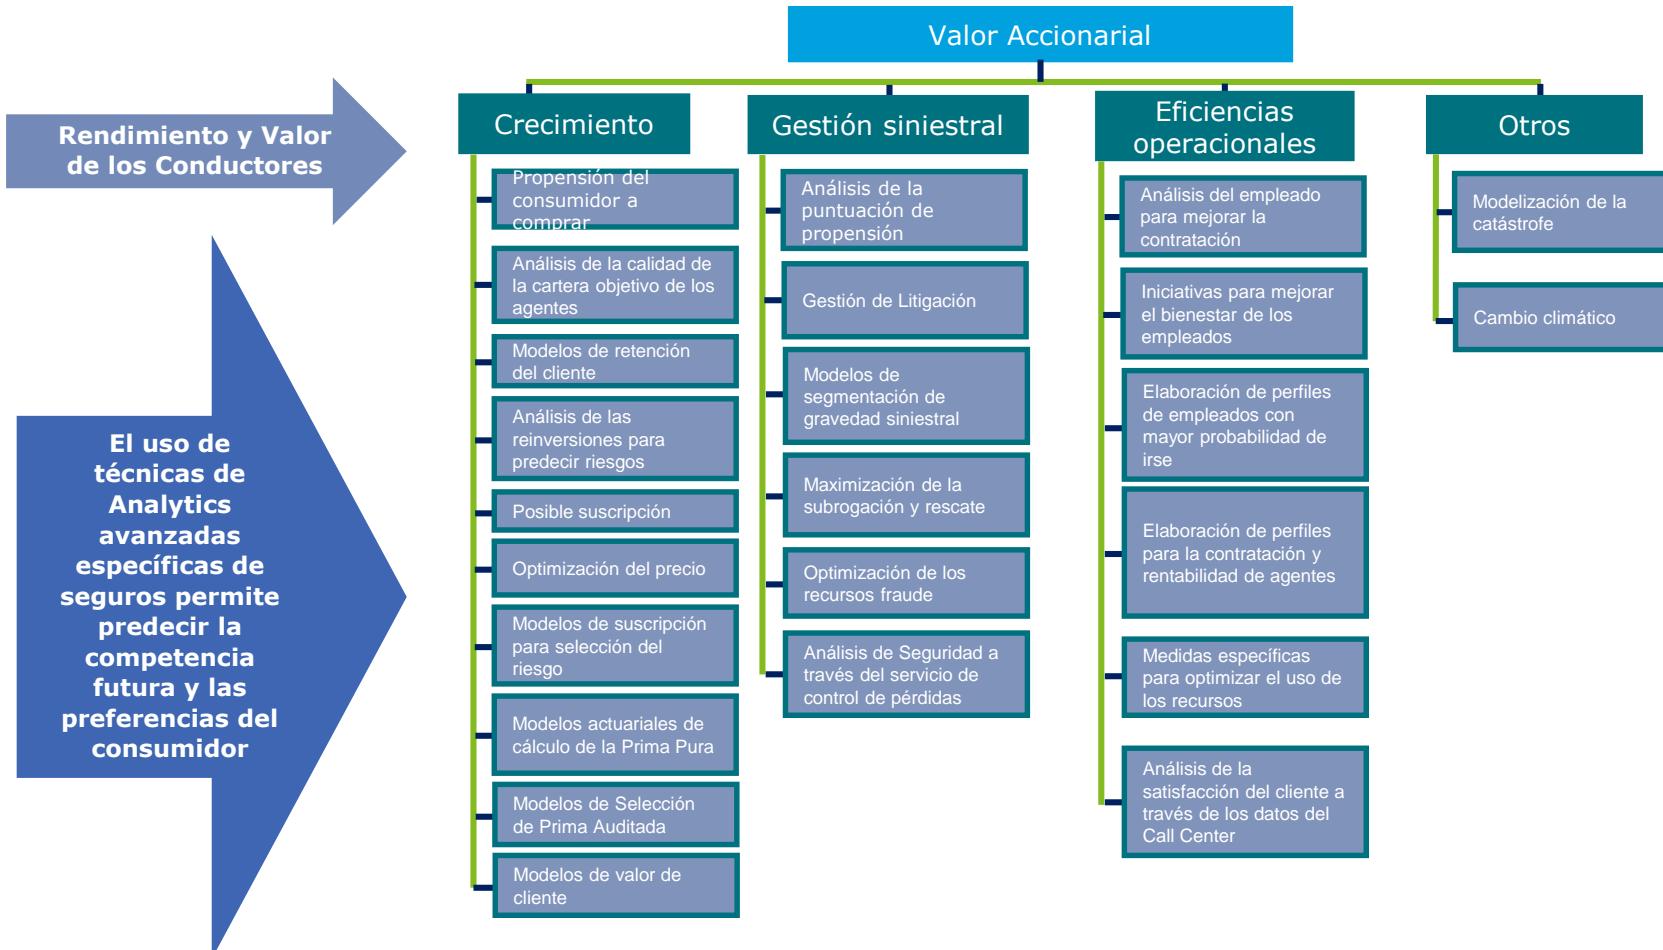
Modelos de pricing Enfoque Metodológico

La construcción individual de diversos modelos predictivos permite que exista una interactuación entre los mismos lo cual permite, de manera progresiva, que finalmente todos formen parte de la estrategia de precios.



Modelos avanzados

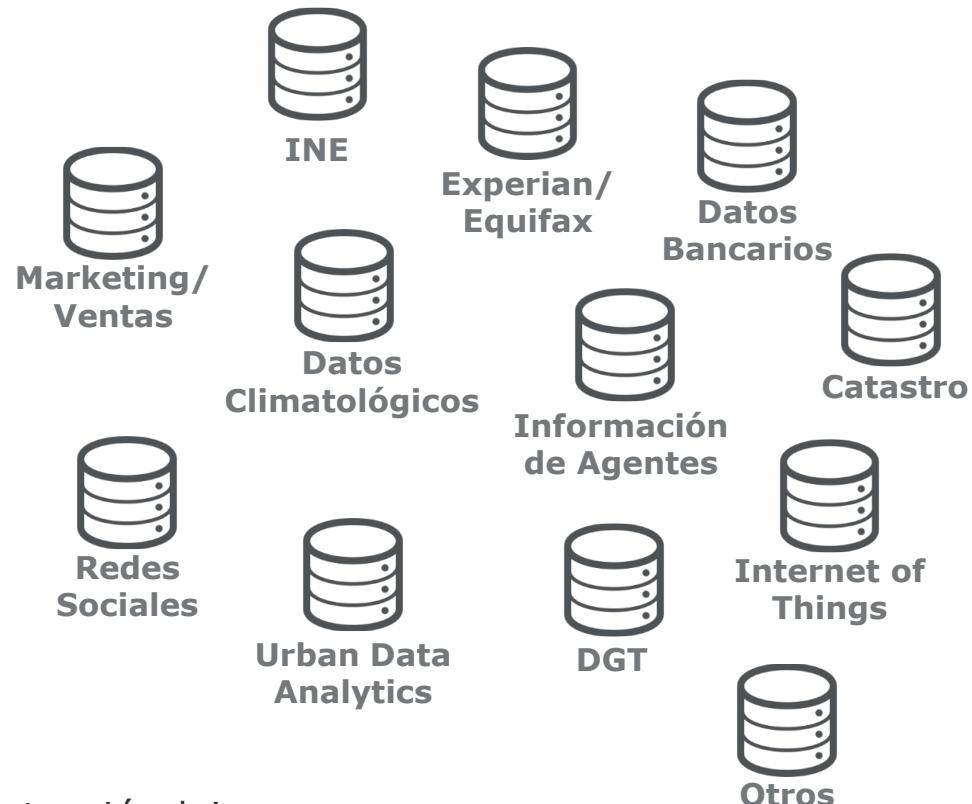
El uso de técnicas de Analytics avanzadas permite aprovechar la inteligencia de negocio tradicional, los análisis predictivos y la visualización



Modelos avanzados

El poder de los datos: Fuentes internas y externas

Hemos visto las posibilidades que nos ofrecen nuestros modelos, pero ¿cómo podemos mejorarlos?

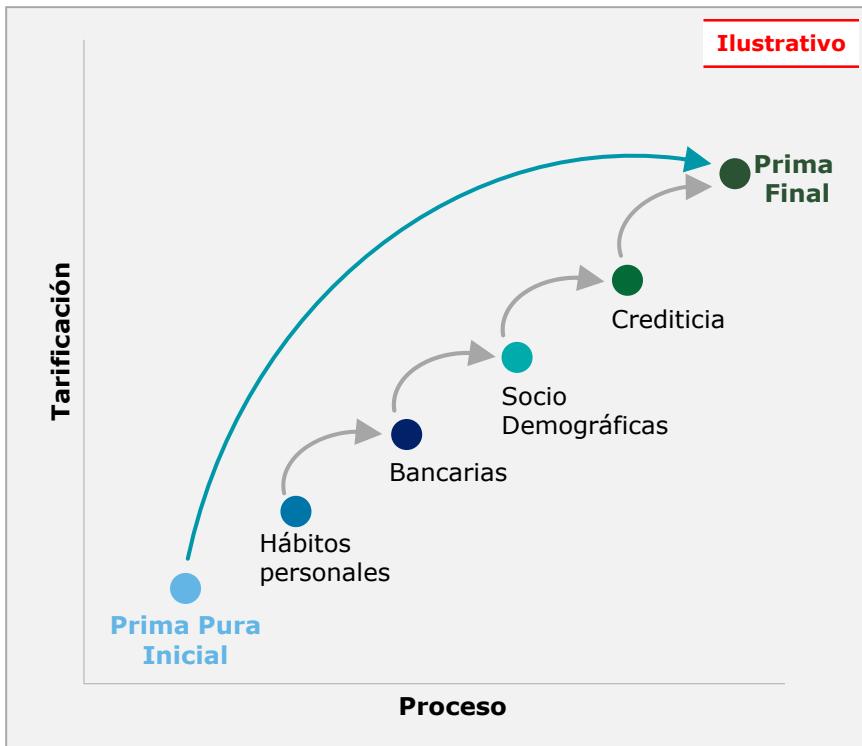


La información se encuentra en todas partes, iúsala!

Modelos avanzados

Modelo de Prima Pura.

Proceso de Aportación de Valor



Modelos de prima pura y tarifa.

En el caso de utilizar información nueva que no esté actualmente en los modelos de prima pura, se propone dos alternativas:

- Dar soporte en la realización de nuevos modelos con dicha información (bancaria, de crédito, sociodemográfica, etc.)
- Asesorar en el reajuste de la tarifa en función de la capacidad de distribución para los distintos canales, que permita lograr las máximas ventas sin afectar a la siniestralidad objetivo global.

En el caso particular del canal bancario, clasificar a los clientes en grupos objetivos de cara a la tarificación para la integración mediante el trasvase de coeficientes entre la entidad aseguradora y el banco.

Modelos avanzados



FINANCIAL [THINKING]

¿Conoces bien
a tus clientes?

¿Qué están
haciendo tus
competidores?

¿Cómo
interactúas con
tus clientes?

¿Puedo vender
más?

¿Se puede mejorar la
rentabilidad de los
agentes?

¿Puedo hacer algún
uso de las redes
sociales?

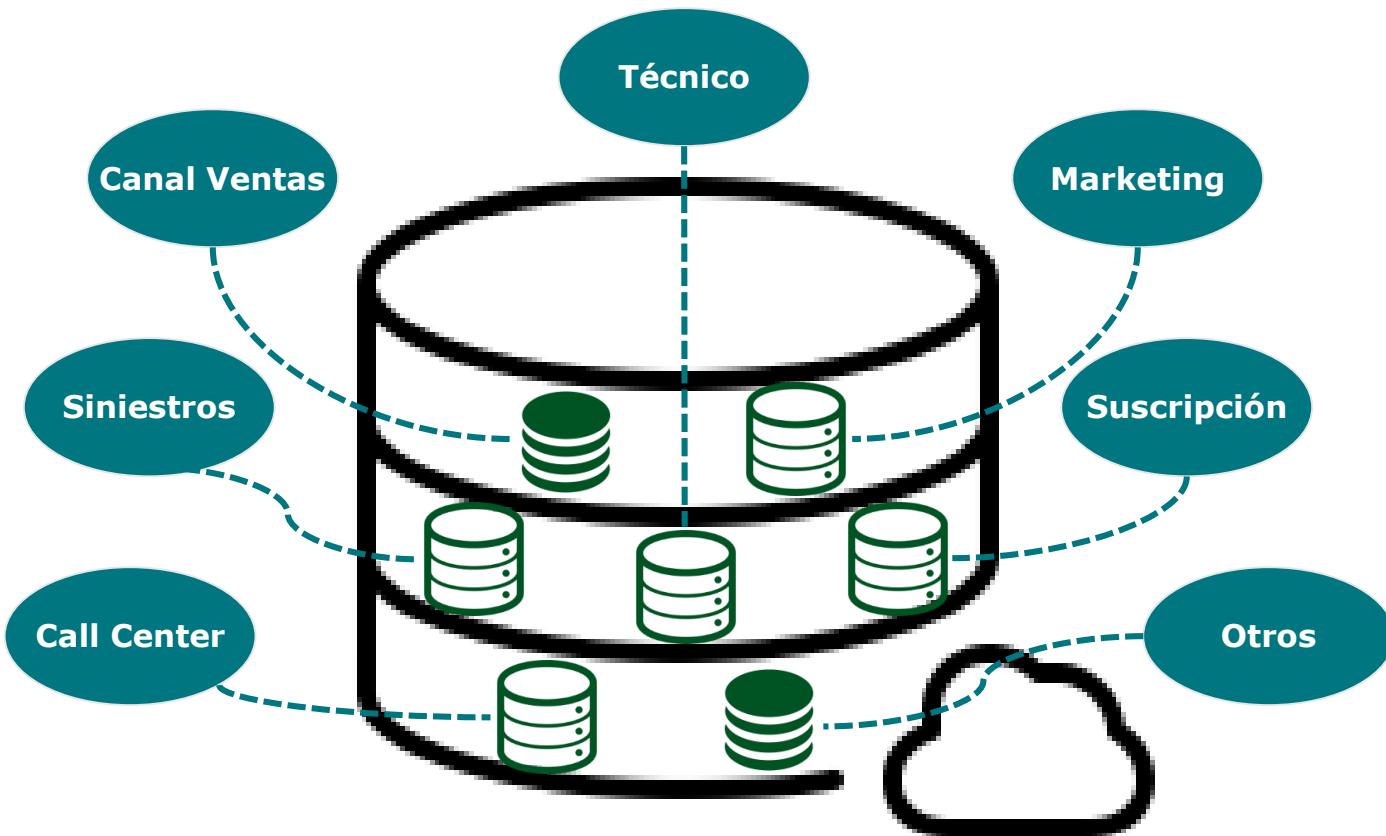
¿Cómo compran
tus clientes?
¿Existe algún
patrón?

¿Uso de información
externa?

¿Puedo ser más eficiente?

Modelos avanzados

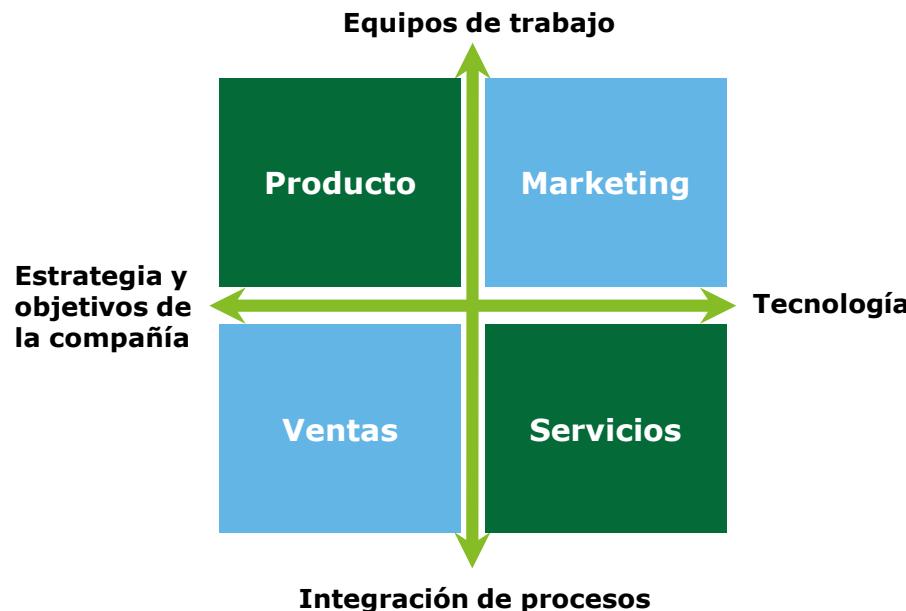
Esto permite la complementación de **información procedente de las diferentes áreas** y de esta forma, crear una **única “red”** en la que todas y cada una de ellas estén conectadas.



Modelos avanzados

Mediante **Advanced Analytics** se puede mejorar la calidad y la eficiencia de los diferentes procesos dentro de una compañía, como por ejemplo:

- Resolución de **problemas complejos**.
- Apoya en la **toma de decisiones** con análisis robustos y sólidos.
- **Interacción** de toda la información de la entidad.
- Eliminación de la **duplicación** de tareas y actividades.
- **Optimización** de los procesos de reporting.



Modelos avanzados



FINANCIAL [THINKING]

Analytics ayuda a mejorar la calidad y la eficiencia de los diferentes procesos de la compañía.

Ayuda en la resolución de problemas complejos fomentando el intercambio de conocimientos entre las diferentes áreas y aportando una mayor visión global.

Apoyo en la toma de decisiones con análisis robustos y sólidos.

Creación de una única base de datos que permite la interacción de toda la información.

Eliminación de la duplicación de tareas y actividades, y optimización de recursos y esfuerzo.

Reducción de los procesos de reporting optimizando y mejorando la obtención de información.

Beneficios

Modelos avanzados

Un “centro de excelencia” de Analytics el cual desarrolle los diferentes modelos adaptándolos a las necesidades de cada área y con la información más relevante, pudiendo provenir ésta de diferentes fuentes dentro de la compañía.

¿Qué necesitamos?

¿Qué se realizaría?

Soporte analítico a planes comerciales.

Expertos de negocio, riesgos, tecnología, gestores de bases de datos, data scientists, etc.

La construcción de una metodología robusta y en consonancia con las necesidades de todas las áreas.

La planificación de reuniones periódicas entre las diferentes áreas para una mejor colaboración entre ellas.

Modelos predictivos de atracción, fidelización, prevención de fuga de clientes, campañas comerciales.

Identificación de cliente de alto potencial, motivos de abandono, patrones de comportamiento.

Nuevas tarifas, propensión, scorings, segmentaciones, satisfacción del cliente, etc.

Modelos avanzados

Etapas / Pasos



SELECCIÓN DE DATOS

Determinar los datos que se adaptan mejor al problema para su posterior modelización.
Recolección de datos de diferentes fuentes internas y externas.



MINERÍA DE DATOS

Limpieza y minería de los datos y construcción de una base de datos de visión global.



ANÁLISIS UNIVARIABLE

Auditoría de los datos mediante análisis de univariables y creación de variables derivadas más explicativas.



MODELADO

Modelado de los datos mediante técnicas y herramientas estadísticas sofisticadas para la obtención de resultados y ayuda a la toma de decisiones.



IMPLEMENTACIÓN

Implementación de los resultados obtenidos tras el modelado.

Analytics ofrece, mediante el estudio estadístico y modelado de los datos, resultados tangibles para adquirir ventajas competitivas en el mercado.

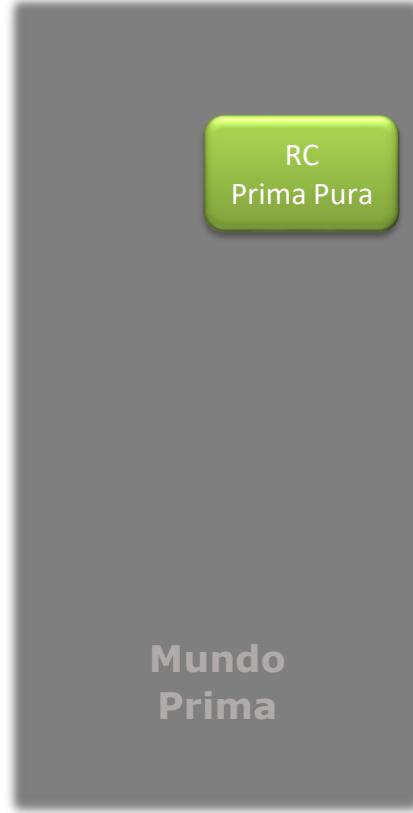
Ejemplos

Modelos avanzados

Estimación Riesgo



Modelos



=

-

+

*

FREQ
RCMAT culpa

*

COSTE
FIJO = 972

FREQ
RCMAT inoc.

*

COSTE
RCMAT inoc.

+

Large Claims
FIJO = 0,08

FREQ
RCCORP culpa

*

COSTE
RCCORP culpa

+

Large Claims
11%

FREQ
RCMAT inoc.
Neg

*

COSTE
RCMAT inoc.
neg

+

Large Claims
FIJO = 0,0

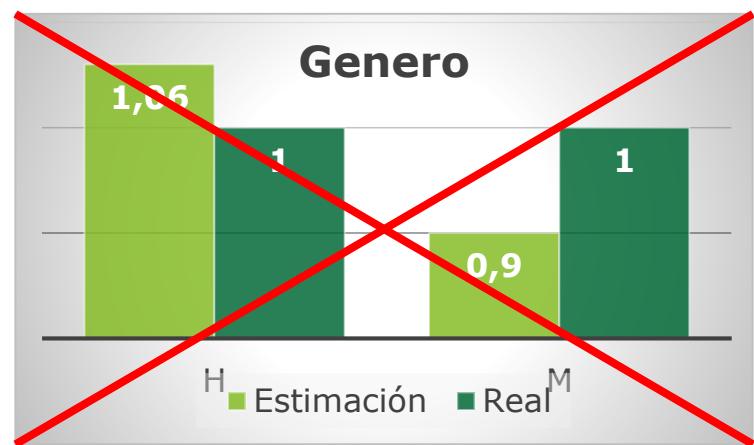
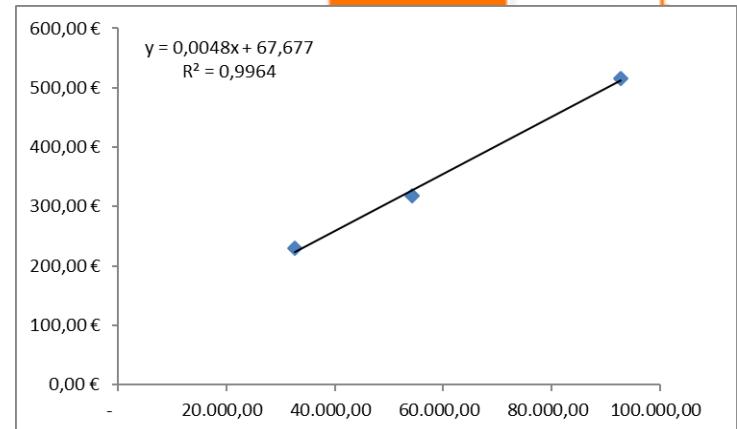
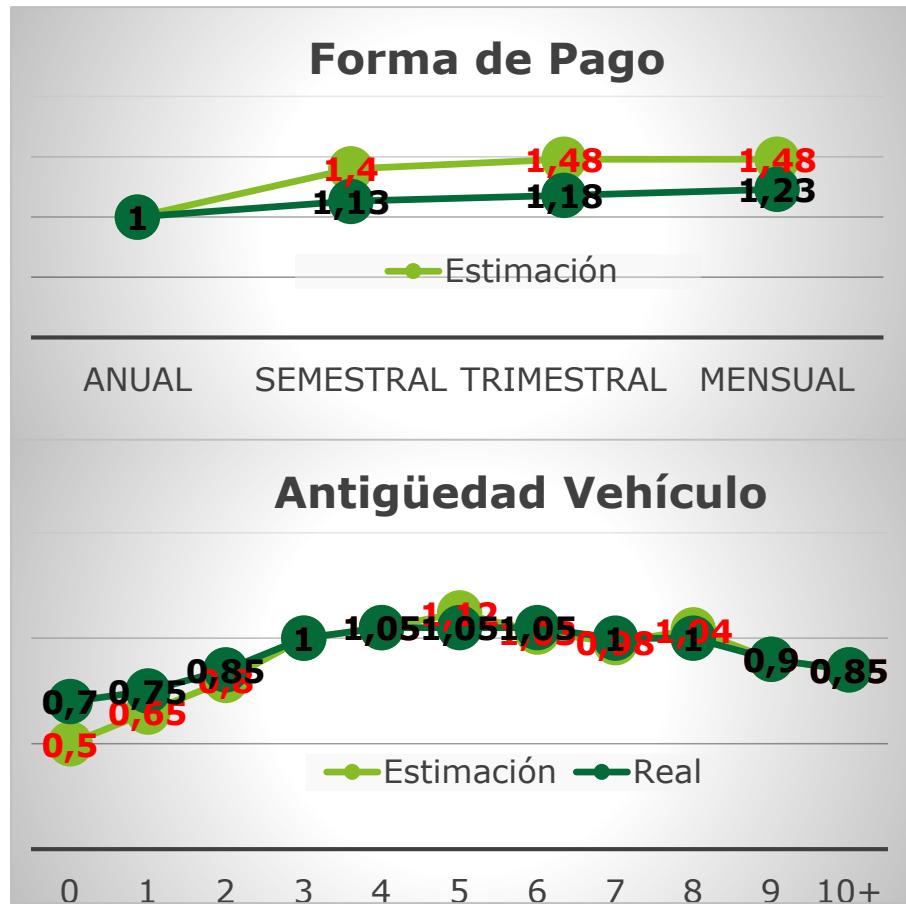
Mundo modelos + ajustes

Modelos avanzados

Modelos Predictivos



Suavizados



Modelos avanzados

Vender el Riesgo



Etapas

